

Rapport Individuel

Issam SALGHAT — Data Scientist

1. Introduction

Dans le cadre du projet d'étude de Mastère Big Data & Intelligence Artificielle, j'ai participé à la conception et au développement d'une plateforme intelligente dédiée à l'optimisation de la mobilité urbaine à partir de données ouvertes. Ce projet avait pour objectif de collecter, traiter, analyser et valoriser des données issues de différentes sources afin de proposer des outils d'aide à la décision pour les citoyens et les gestionnaires urbains.

Au sein de l'équipe projet, j'ai occupé le rôle de Data Scientist. Mes missions ont porté sur la préparation des données pour l'apprentissage, la sélection des variables pertinentes, le développement des modèles prédictifs de trafic — un modèle statistique ARIMA et un réseau de neurones MLP — ainsi que sur l'évaluation, l'optimisation et la comparaison de leurs performances.

2. Missions réalisées

Mes principales contributions au projet ont été les suivantes :

- Préparation et structuration des séries temporelles de trafic pour l'apprentissage.
- Sélection des variables pertinentes et ingénierie de features (heure, jour, week-end, jours fériés, heures de pointe).
- Développement du modèle statistique ARIMA pour la composante temporelle linéaire.
- Développement d'un modèle de réseau de neurones (MLP) appliqué aux résidus du modèle ARIMA.
- Optimisation des hyperparamètres des deux modèles.
- Évaluation des performances et production des métriques (RMSE, MAE, MAPE).
- Comparaison des résultats entre modèles et avec une baseline naïve de référence.
- Participation aux tests de validation du modèle et à la documentation technique.

Ces missions m'ont permis d'intervenir sur l'ensemble de la chaîne de modélisation, depuis la préparation des données jusqu'à l'évaluation rigoureuse des prédictions exposées aux utilisateurs.

3. Défis rencontrés

L'un des principaux défis a été la qualité des données temporelles. Les séries de trafic présentaient des valeurs manquantes et des irrégularités d'échantillonnage qui devaient être traitées avant l'apprentissage, sous peine de dégrader fortement la qualité des prédictions.

Le choix des paramètres du modèle ARIMA a également représenté une difficulté : déterminer les ordres adaptés (autorégressif, différenciation, moyenne mobile) a nécessité plusieurs itérations et une analyse fine du comportement de la série. La gestion du surapprentissage du MLP a constitué un autre enjeu majeur, traité par le dimensionnement du réseau et la limitation du nombre d'itérations afin de préserver sa capacité de généralisation.

Enfin, la comparaison rigoureuse des performances entre modèles et l'interprétation des résultats ont exigé une méthodologie d'évaluation soignée — notamment un découpage temporel entraînement/test évitant toute fuite de données — pour garantir des conclusions fiables.

4. Analyse critique des limites techniques

Malgré les résultats obtenus, plusieurs limites ont été identifiées. La première concerne le volume et la profondeur d'historique des données disponibles pour l'entraînement : un historique plus long permettrait au modèle de mieux capturer les saisonnalités longues et les événements exceptionnels.

Une seconde limite tient à la persistance du modèle : dans la version actuelle, le modèle est ré-entraîné au démarrage plutôt que sauvegardé, ce qui est acceptable pour un prototype mais devrait être industrialisé pour un déploiement à grande échelle. Enfin, l'approche hybride ARIMA + MLP, bien que performante, reste perfectible : elle n'exploite pas encore des architectures séquentielles avancées telles que les réseaux LSTM, qui pourraient améliorer la prédiction sur des horizons plus longs.

5. Compétences techniques et méthodologiques

J'ai développé plusieurs compétences techniques, telles que :

- Modélisation des séries temporelles (ARIMA).
- Machine Learning et réseaux de neurones (MLP) avec scikit-learn.
- Feature engineering et sélection de variables.
- Évaluation de modèles et métriques (RMSE, MAE, MAPE).
- Analyse statistique et diagnostic des résidus.
- Manipulation de données avec Python, Pandas et NumPy.
- Utilisation de statsmodels et mise en place de backtests temporels.

En termes de compétences méthodologiques, j'ai progressé sur :

- Démarche scientifique d'évaluation (baseline, validation temporelle, comparaison objective).
- Travail collaboratif au sein d'une équipe pluridisciplinaire.
- Gestion de projet Agile et planification des tâches.
- Résolution de problèmes complexes.

6. Forces personnelles et faiblesses identifiées

Ce projet m'a permis d'identifier plusieurs points forts :

- Capacité d'analyse et esprit de synthèse face à des données complexes.
- Rigueur scientifique dans la démarche de modélisation et d'évaluation.
- Aptitude à résoudre des problèmes techniques complexes.
- Curiosité technique et volonté d'apprentissage.
- Esprit d'équipe et collaboration avec les autres membres du groupe.

Ce projet a également mis en évidence certains axes de progression. J'ai parfois consacré beaucoup de temps à l'optimisation et au réglage fin des modèles, au détriment de la formalisation intermédiaire des résultats. Sur le plan technique, je dois encore approfondir le Deep Learning avancé et mieux maîtriser les architectures séquentielles modernes telles que les réseaux LSTM et les Transformers.

7. Axes d'amélioration pour les futurs projets

Pour mes futurs projets professionnels et académiques, je souhaite :

- Mettre en place un suivi d'expériences et un versioning des modèles (par exemple avec MLflow).
- Industrialiser l'entraînement avec une persistance des modèles entraînés.
- Approfondir le deep learning séquentiel (LSTM, GRU, Transformers).
- Formaliser davantage les résultats intermédiaires tout au long du projet.

Ces axes d'amélioration me permettront d'accroître mon efficacité et ma capacité à intervenir sur des projets de modélisation de plus grande envergure.

8. Perspectives d'évolution de la solution

- Ajouter des modèles de réseaux de neurones récurrents (LSTM/GRU) pour les dépendances à long terme.
- Tester des approches ensemblistes telles que XGBoost et les comparer au modèle hybride.
- Utiliser davantage de données en temps réel pour affiner les prédictions.
- Développer un système de prédiction multi-sources combinant trafic, météo, événements et signalements citoyens.

9. Conclusion

Cette expérience a représenté une étape importante dans mon parcours de formation. Elle m'a permis de mettre en pratique les compétences acquises durant le Mastère Big Data & Intelligence Artificielle, en particulier en modélisation prédictive, tout en découvrant les contraintes réelles d'un projet complet, de la donnée brute jusqu'à la mise en production des prédictions.

Au-delà des aspects techniques, ce projet m'a permis de développer des compétences méthodologiques et relationnelles essentielles aux métiers de la data science. Les enseignements tirés de cette expérience constitueront un atout important pour mes futures missions professionnelles.